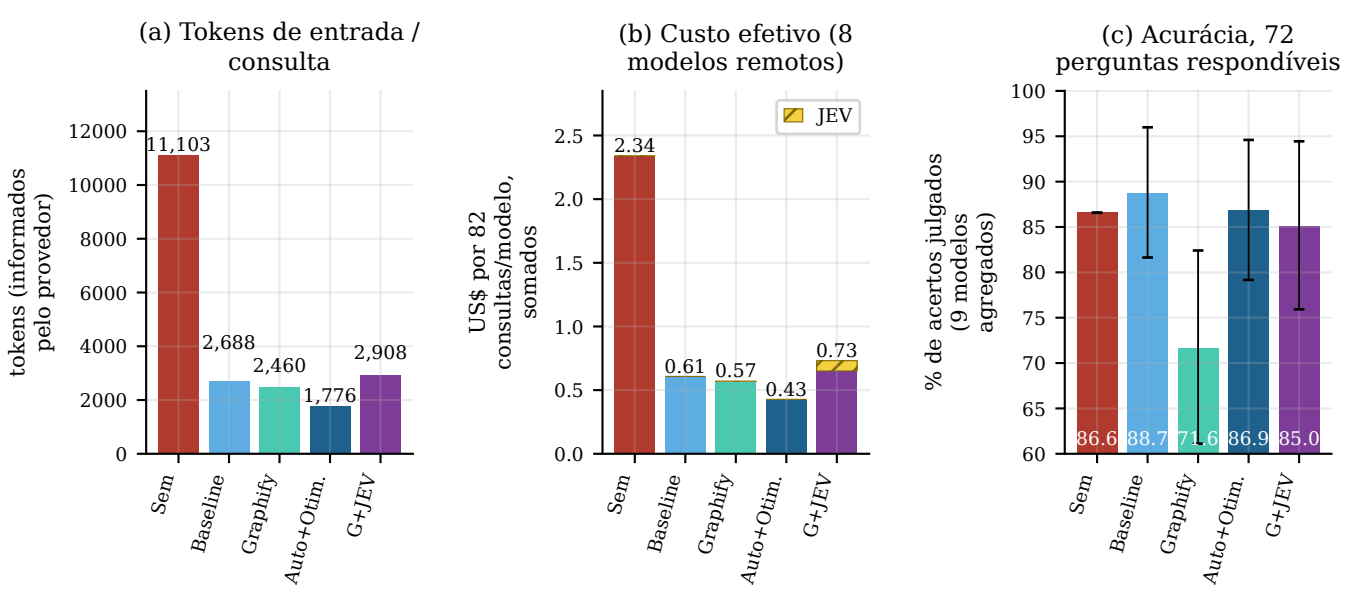
(a) Tokens de entrada / consulta
tokens (informados pelo provedor)
12000
10000
8000
6000
4000
2000
0
11,103
2,688
2,460
1,776
2,908
Sem
Baseline
Graphify
Auto+Otim.
G+JEV
(b) Custo efetivo (8 modelos remotos)
US$ por 82 consultas/modelo, somados
JEV
2.5
2.0
1.5
1.0
0.5
0.0
2.34
0.61
0.57
0.43
0.73
Sem
Baseline
Graphify
Auto+Otim.
G+JEV
(c) Acurácia, 72 perguntas respondíveis
% de acertos julgados (9 modelos agregados)
100
95
90
85
80
75
70
65
60
86.6
88.7
71.6
86.9
85.0
Sem
Baseline
Graphify
Auto+Otim.
G+JEV